

分类号: \_\_\_\_\_

密级: \_\_\_\_\_公开

UDC \_\_\_\_\_

学号: 20142210069

# 华南师范大学

South China Normal University

## 学士学位论文

基于神经网络的花苗分类

学位申请人 张泓铨

专业学位名称 信息与计算科学

专业学位领域 理学

所在院系 数学科学学院

导师姓名及职称 杨坦 讲师

2018年4月19日



# 目 录

<b>第 1 章 绪论 .....</b>	<b>1</b>
<b>第 2 章 论文正文 .....</b>	<b>3</b>
2.1 花苗分类问题 .....	3
2.2 数据预处理 .....	5
2.2.1 掩模构建与形态学去噪 .....	5
2.2.2 形态学去噪 .....	6
2.2.3 边框裁剪与尺寸统一化 .....	6
2.3 BP 神经网络与卷积神经网络 .....	8
2.3.1 神经网络的构造与前向传播 .....	8
2.3.2 神经网络的反向传播 .....	10
2.3.3 激活函数 .....	14
2.3.4 传统 BP 网络的应用 .....	17
2.3.5 梯度下降方法 .....	19
2.3.6 正则化与 dropout .....	20
2.3.7 卷积神经网络概述 .....	23
2.3.8 经典 CNN 模型 .....	25
2.3.9 CNN 的应用 .....	28
2.4 NN+X .....	30
2.4.1 改进思路 .....	30
2.4.2 BP 神经网络 +X .....	32
2.4.3 CNN+X .....	35
2.5 参考文献 .....	37
<b>第 3 章 结论 .....</b>	<b>39</b>
<b>附录 A 外文资料原文 .....</b>	<b>41</b>
A.1 First Principles .....	41
A.1.1 Typography exists to honor content. ....	41
A.1.2 Letters have a life and dignity of their own. ....	42
<b>附录 B 其它附录 .....</b>	<b>45</b>

致 谢 .....	47
作者攻读学位期间发表的学术论文目录 .....	49

## 第 1 章 緒論

大量数据代表了价值。数据背后通常隐含着客观规律，如果数据量足够大的话，其规律是可以被认知和学习的，其催生了机器学习的研究方向，研究如何用数据进行建模与变现。然而，由于数据量极大，而且所涉及的算法会很复杂，通常不可能进行人为的计算，即使是用计算机进行计算，也对计算机的处理速度，内存，储存空间提出了一定的要求。另一方面，如若要进行机器学习，除了计算机硬件的要求之外，还需要软件与算法的支持，其中，算法是机器学习的核心。历史发展来看，计算机硬件，用于机器学习的软件与算法的发展是相辅相成的。

在 20 世纪 40 年代，人们开始研究人工智能，由于生物学的发展，人们模仿人类的神经元运作而提出了神经网络的原型：M-P 神经元模型，并提出了激活函数的概念。在 20 世纪 50 年代到 60 年代，感知器算法、梯度下降法、最小二乘法等求解算法面世，而且提出了感知器，并开始应用在文字、语音、信号等领域。在 20 世纪 60 年代到 70 年代，神经网络算法因感知器的缺陷而衰落。在 70 年代到 80 年代，神经网络的种类变得丰富起来，涌现出 BP 神经网络，RBF 神经网络等各种网络，并提出了深度学习的概念与卷积神经网络（CNN）和循环神经网络（RNN）的结构。90 年代后，一些有别于神经网络的算法面世，如 SVM，决策树，boosting 与随机森林等方法，从不同的角度对机器学习算法进行丰富。在 2006 年，Hinton 提出了解决深度学习中梯度消失问题的解决方法之后，深度学习开始爆发。2012 年，ReLU 激活函数的提出，进一步抑制了梯度消失的问题，并且深度学习在语音和图像方面开始有惊人的表现。2012 年，在 ImageNet 图像识别比赛上，AlexNet 通过构建一定深度的 CNN 夺得冠军，其性能彻底击败了 SVM。需注意的是，AlexNet 首次使用了 ReLU 激活函数，Dropout 防止过拟合方法，以及 GPU 加速。之后，在 AlexNet 的结构上做优化，又提出了其他更强大的模型，如 VGGNet，Inception 系列，ResNet 等。强化学习和迁移学习的提出，进一步增强了模型的性能。

本论文基于 kaggle (全球数据科学平台) 的花苗分类竞赛 (Plant Seedlings

---

Classification<sup>1)</sup> 中的数据集，探究传统机器学习算法（SVM，决策树，随机森林与 boosting 等）、深度学习算法（AlexNet，VGGNet，InceptionV3）的原理与性能，并对其尝试做优化与结合（如 AlexNet+SVM 等）。

---

<sup>1</sup><https://www.kaggle.com/c/plant-seedlings-classification>

## 第 2 章 论文正文

### 2.1 花苗分类问题

该问题来自于 kaggle 的 Plant Seedlings Classification 竞赛。给定的 13 类花苗(有枝干, 树叶, 无花) 的四千余张彩色图片用于训练、构建模型。其数据基本情况如表 2.1

表 2.1 数据基本情况

序号	种类	样本数量
1	Black-grass	263
2	Charlock	390
3	Cleavers	287
4	Common Chickweed	611
5	Common wheat	221
6	Fat Hen	475
7	Loose Silky-bent	654
8	Maize	221
9	Scentless Mayweed	516
10	Shepherds Purse	231
11	Small-flowered Cranesbill	496
12	Sugar beet	385
总和	-	4750

而且每一张的图片大小都有可能不同。每一类的图像的例子如图 2.1, 2.2, 2.3, 2.4



图 2.1 从左到右分别为 Black-grass, Charlock, Cleavers 的一张图片, 像素分别为  $370 \times 368$ ,  $484 \times 484$ ,  $346 \times 346$



图 2.2 从左到右分别为 Common Chickweed, Common wheat, Fat Hen 的一张图片, 像素分别为  $542 \times 542$ ,  $524 \times 524$ ,  $312 \times 312$



图 2.3 从左到右分别为 Loose Silky-bent, Maize, Scentless Mayweed 的一张图片, 像素分别为  $490 \times 490$ ,  $417 \times 417$ ,  $228 \times 228$



图 2.4 从左到右分别为 Shepherds Purse, Small-flowered Cranesbill, Sugar beet 的一张图片, 像素分别为  $542 \times 542$ ,  $733 \times 733$ ,  $546 \times 546$

由于所涉及到的数据为彩色图像, 而花苗的特征为绿色, 故考虑使用 opencv 的方法, 通过建立掩膜筛选出花苗的图像, 进而将彩色图像转化为灰度图像或二值图像, 从而达到降维的目的。而即使降维之后, 为了确保图像失真不大, 所以至少将图像转化为  $64 \times 64$  的灰度图像矩阵。若考虑直接采用 Logistic、SVM 或决策树方法, 则需要将  $64 \times 64$  的灰度图像矩阵拉伸为  $4096 \times 1$  的图像, 然而假设用全部的数据进行训练, 也只有 4750 个样本, 训练时极容易导致过拟合, 但是, 考虑集成学习的方法或是带 dropout 的 BP 神经网络可以一定程度上防止过拟合。考虑到为涉及图像的分类问题, 可以采用卷积神经网络 (CNN)。由于是 13 类的分类问题, 且样本数较少, 可以进一步考虑在用 SVM、Logistic 或决策树方法来替代神经网络最后的 softmax 层, 或许能起到更好的效果。

## 2.2 数据预处理

### 2.2.1 掩模构建与形态学去噪

对于花苗图像，我们可以看到，花苗的背景通常为黄土、砂砾或塑料箱等，而绿色的花苗则显得非常好辨认。而且我们面对的花苗是绿色的，因而考虑设置一个 hsv 范围，将绿色的部分从图像中剥离出来。于是我们首先将花苗图像进行颜色空间的转换，从 rgb 颜色空间转化为 hsv 颜色空间，之后设定 hsv 颜色空间为 [26,43,46] 和 [99,255,255]，在原图中过滤出在这个 hsv 颜色空间的图像得到掩膜，若在这个区间中，则为白色，否则为黑色。之后可以通过该掩膜对原图进行位运算，则可得到原图的图像。其部分代码如下

```

1 import cv2
2 # 假设待处理的图像为img
3 # rgb图像转化为hsv图像
4 hsv = cv2.cvtColor(img, cv2.COLOR_BGR2HLS)
5 # 绿色的阈值(HSV)
6 lower_green = np.array ([26,43,46])
7 upper_green = np.array ([99,255,255])
8 # 根据阈值构建掩膜
9 mask = cv2.inRange(hsv,lower_green,upper_green)
10 # 对原图像和掩膜进行位运算
11 res = cv2.bitwise_and(img,img,mask=mask)

```

得到的结果如下，以 Black-grass, Charlock, Cleavers 种类的各一个图像为例，如图 2.5, 2.6, 2.6, 2.7



图 2.5 Black-grass 的一个图像，其大小为  $370 \times 368$ ，从左到右依次为原图，掩膜图像，通过掩膜对原图过滤的图像

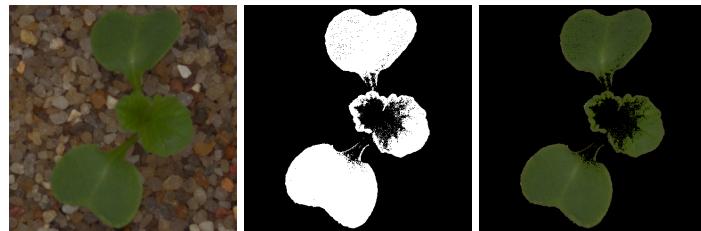


图 2.6 Charlock 的一个图像，其大小为  $484 \times 484$ ，从左到右依次为原图，掩膜图像，通过掩膜对原图过滤的图像

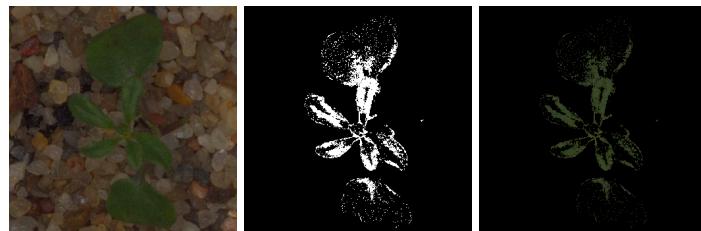


图 2.7 Cleavers 的一个图像，其大小为  $346 \times 346$ ，从左到右依次为原图，掩膜图像，通过掩膜对原图过滤的图像

## 2.2.2 形态学去噪

对于用掩模处理后的花苗二值图像，考虑到在花苗所在盆栽可能会有一些小草，通过掩模处理后会有噪声。因而考虑用形态学方法去噪。

对于一个二值图像，比较常用的去噪方法是形态学去噪，而这通常涉及两种形态学转换，分别为腐蚀和膨胀，其涉及的原理较简单。对于腐蚀，先定义一个窗口，窗口将沿着图像滑动，以遍历整个图像。滑动过程中，窗口内所有像素不全为 1 时，则令窗口中的所有像素等于 0；若窗口内所有像素全为 1 时，则不做操作。选用一个合适尺寸的窗口，对于腐蚀之后的图片，其白噪声点可以消除，但也会对物体的边缘进行腐蚀。膨胀则与腐蚀相反，区别在于滑动过程中，窗口内元素只要有 1，则整个窗口元素都令为 1，这样会增大物体的尺寸。通常对于有白噪声的图片，先腐蚀再膨胀可以消除白噪声，但一定程度会导致物体失真。但由于用掩模处理后的图像，其物体十分明显，用形态学方法去噪后失真的可能性不大。因而考虑用形态学方法去噪。

## 2.2.3 边框裁剪与尺寸统一化

我们从掩膜图像可以看出，目标图像（白色部分）只是占所有图像的很小一部分，而其余其余部分为黑色，而这其余的部分往往是无效的。现在考虑用一个

矩形边框去提取出图像的有效区域，而将无效区域剔除。方法是访问图像中有效区域的宽度最小值和最大值，以及高度最小值和最大值，从而确定矩形边框区域。其效果图 2.8 所示



图 2.8 Sugar beet 的一个图像，其大小为  $546 \times 546$ ，从左到右依次为原图，掩膜图像，对掩膜图像矩形裁剪之后的图像，其大小为  $199 \times 530$

实现这个效果的代码如下

```
1 import cv2
2 # 获得矩形边框的最小宽高以及宽度和高度
3 x,y,w,h = cv2.boundingRect(mask_temp)
4 # 在原掩膜图像中选取矩形边框
5 mask_tg = mask[y:(y+h),x:(x+w)]
```

由于卷积神经网络需要同样大小尺寸的输入，所以考虑将图像统一尺寸归一化为统一的大小。内插的方法是 INTER-CUBIC，其结果如图 ??

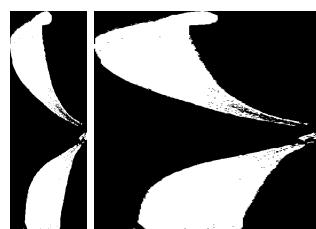


图 2.9 Sugar beet 的一个图像，左边为矩形裁剪之后的图像，大小为  $199 \times 530$ ，右边为尺寸统一后的图像，大小为  $96 \times 96$

实现这个效果的代码如下

```
1 import cv2
2 # 尺寸变换
3 mask_tg_rs = cv2.resize(mask_tg,[96,96], interpolation=cv2.INTER_CUBIC)
```

最后，对所有的图片都做上述操作。每张图片的掩膜的尺寸归一后的图像作为输入，需要注意的是，图片格式为 uint8，需要转化为 float 才不会出问题，用以下代

码可以解决该问题。

```
1 from skimage import img_as_float
2 imginput = img_as_float(mask_tg_rs)
```

制作训练模型所需的数据集时，对原有的图片输入，通过以上变换之后所得到的 `imginput` 作为数据集的输入，而对原有的图片的名字进行 one-hot 编码处理作为数据集的输出。采用自助法分割训练集和验证集。训练集和验证集的样本数量比为 7 : 3。在制备数据集输入时，制备三种规格分别为  $64 \times 64$ ,  $96 \times 96$ ,  $128 \times 128$  的数据集输入，而数据集输出不变，以探究不同大小的图片输入对神经网络性能的影响。为了方便表示，将上面三种规格的数据分别命名为 I64, I96, I128，如表 2.2 所示

表 2.2 训练集与验证集的构成

数据集名称	数据集用途	输入的数据特征	输出的数据特征
I64	训练集	3325, 64, 64, 1	3325, 10
	验证集	1425, 64, 64, 1	1425, 10
I96	训练集	3325, 96, 96, 1	3325, 10
	验证集	1425, 96, 96, 1	1425, 10
I128	训练集	3325, 128, 128, 1	3325, 10
	验证集	1425, 128, 128, 1	1425, 10

## 2.3 BP 神经网络与卷积神经网络

### 2.3.1 神经网络的构造与前向传播

神经网络是由单个或多个神经元组成。图 2.10 是单个神经元的构造。

该神经元的输入由三个数据  $x_1, x_2, x_3$  以及偏置项 (bias)+1 组成，通过神经元后输出的表达式为

$$h_{W,b}(x) = f(W^T x + b) = f\left(\sum_{i=1}^3 W_i x_i + b\right) \quad (2.1)$$

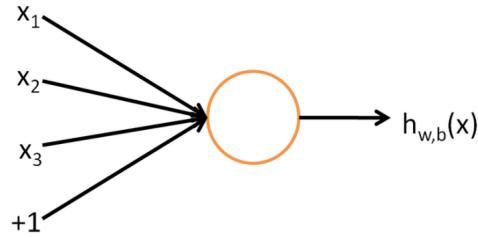


图 2.10 神经元

其中  $f$  为激活函数。激活函数是为了将线性项  $W^T x$  变换为非线性。在 BP 中，较常用的激活函数为 sigmoid 函数，其表达式如下

$$f(z) = \frac{1}{1 + \exp(-z)} \quad (2.2)$$

另外，令  $b = w_0$ ，则可重新定义  $W = (w_0, w_1, w_2, w_3)^T$ ， $x = (1, x_1, x_2, x_3)$ ，于是可将上式写为

$$h_{W,b}(x) = f(W^T x) \quad (2.3)$$

下面讨论神经网络。多个神经元可以组成一个层，多个层互相连接可以组成神经网络。其中，接受数据输入的层为输入层，数据计算后的数据的输出层，中间的层则称为隐含层。图 2.11 是含有两个隐含层的神经网络。如图，最左边的为输入

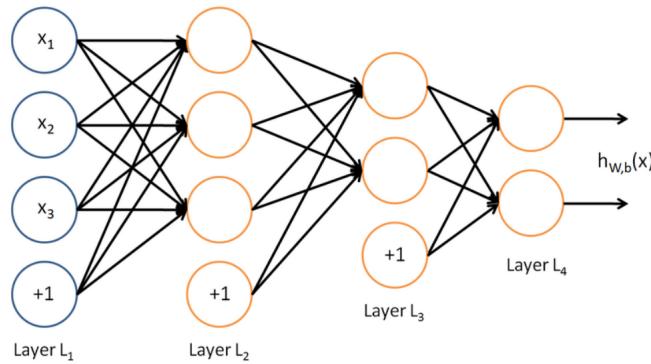


图 2.11 含有两个隐含层的神经网络

层，即图中的 Layer L1，最右边的为输出层，即图中的 Layer L4，中间的所有层，即图中的 Layer L2，Layer L3 为隐含层。

我们用  $n_l$  来表示网络的层数，记第  $i$  层为  $L_i$ ，于是输入层为  $L_1$ ，输出层为  $L_{n_l}$ 。由于神经网络可以有任意多的隐层以及隐藏神经元，则我们记  $W_{ij}^{(l)}$  为第  $l$  层

第  $j$  单元以及第  $l+1$  层第  $i$  单元之间的连接权重， $b_i^{(l)}$  为第  $L+1$  层第  $i$  单元的偏执。我们用  $a_i^{(l)}$  表示第  $l$  层第  $i$  单元的激活值（输出值），则有

$$a_i^{(l+1)} = f\left(\sum_{j=1}^{S_l} W_{ij}^{(l)} a_j^{(l)} + b_i^{(l)}\right) \quad (2.4)$$

其中当  $l=1$  时， $a^{(l)} = x$ ， $x$  为输入向量  $(x_1, x_2, \dots, x_{S_l})$ ， $S_l$  指第  $l$  层的神经元个数，我们用  $z_i^{(l+1)}$  表示第  $l+1$  层第  $i$  单元输入加权和（包括偏置），即

$$z_i^{(l+1)} = \sum_{j=1}^{S_l} W_{ij}^{(l)} a_j^{(l)} + b_i^{(l)} \quad (2.5)$$

则有

$$a_i^{(l+1)} = f(z_i^{(l+1)}) \quad (2.6)$$

$$h_{W,b}(x) = a^{(n_l)} = f(z^{(n_l)}) \quad (2.7)$$

上述过程称为神经网络的前向传播。

### 2.3.2 神经网络的反向传播

根据上面的前向传播，我们设神经网络的各层表示为  $L_1, L_2, \dots, L_{n_l}$ ，其中， $L_{n_l}$  为输出层，对于输出层，假设输出层输出为  $t = a^{(n_l)}$ ， $y$  为标签，则若为回归问题，则代价函数使用 MSE，即

$$J(W, b; x, y) = \frac{1}{2} \|t - y\|^2 \quad (2.8)$$

接下来计算输出层的残差

$$\begin{aligned}
 \delta_i^{(n_l)} &= \frac{\partial}{\partial z_i^{(n_l)}} J(W, b; x, y) \\
 &= \frac{\partial}{\partial z_i^{(n_l)}} \frac{1}{2} \|y - h_{W,b}(x)\|^2 \\
 &= \frac{\partial}{\partial z_i^{(n_l)}} \frac{1}{2} \sum_{j=1}^S (y_j - a_j^{(n_l)})^2 \\
 &= \frac{\partial}{\partial z_i^{(n_l)}} \frac{1}{2} \sum_{j=1}^S (y_j - f(z_i^{(n_l)}))^2 \\
 &= -(y_i - f(z_i^{(n_l)})) \cdot f'(z_i^{(n_l)}) \\
 &= -(y_i - a_i^{(n_l)}) \cdot f'(z_i^{(n_l)})
 \end{aligned} \tag{2.9}$$

下面考虑残差的递推算法，以输出层前一层为例。由前向传播我们可以推导出

$$z_i^{(l+1)} = \sum_{j=1}^{S_l} W_{ij}^{(l)} f(z_j^{(l)}) + b_i^{(l)} \tag{2.10}$$

则有

$$z_i^{(n_l)} = \sum_{j=1}^{S_l} W_{ij}^{(n_l-1)} f(z_j^{(n_l-1)}) + b_i^{(n_l-1)} \tag{2.11}$$

于是有

$$\frac{\partial z_i^{(n_l)}}{\partial z_i^{(n_l-1)}} = \sum_{j=1}^{S_l} W_{ij}^{(n_l-1)} f'(z_j^{(n_l-1)}) \tag{2.12}$$

则可以得到输出层前一层的残差

$$\begin{aligned}
 \delta_i^{(n_l-1)} &= \frac{\partial}{\partial z_i^{(n_l-1)}} J(W, b; x, y) \\
 &= \frac{\partial J(W, b; x, y)}{\partial z_i^{(n_l)}} \cdot \frac{\partial z_i^{(n_l)}}{\partial z_i^{(n_l-1)}} \\
 &= \sum_{j=1}^{S_l} \delta_j^{(n_l)} W_{ij}^{(n_l-1)} f'(z_j^{(n_l-1)})
 \end{aligned} \tag{2.13}$$

将  $n_l - 1$  与  $n_l$  的关系替换为  $l$  与  $l + 1$  的关系，则可得到

$$\delta_i^{(l)} = \frac{\partial}{\partial z_i^{(l)}} J(W, b; x, y) = \left( \sum_{j=1}^{S_{l+1}} W_{ji}^{(l)} \delta_j^{(l+1)} \right) f'(z_i^{(l)}) \quad (2.14)$$

若取函数  $f$  为 sigmoid 函数，则有

$$f'(z_i^{(l)}) = f(z_i^{(l)}) \circ (1 - f(z_i^{(l)})) = a_i^{(l)} \circ (1 - a_i^{(l)}) \quad (2.15)$$

其中  $\circ$  代表点乘。于是可得到  $\sigma_j^{(l+1)}$  到  $\sigma_j^{(l)}$  的递推式：

$$\delta_i^{(l)} = \left( \sum_{j=1}^{S_{l+1}} W_{ji}^{(l)} \delta_j^{(l+1)} \right) (a_i^{(l)} \circ (1 - a_i^{(l)})) \quad (2.16)$$

反向传播，一般采用梯度下降法对每一层的权重进行调整，即

$$W_{ij}^{(l)} = W_{ij}^{(l)} - \alpha \frac{\partial}{\partial W_{ij}^{(l)}} J(W, b; x, y) \quad (2.17)$$

其中， $\alpha$  是学习率。因而需要求权重  $W_{ij}^{(l)}$  对于代价函数的偏导，此时可使用当前层的残差来进行计算，即

$$\frac{\partial}{\partial W_{ij}^{(l)}} J(W, b; x, y) = \frac{\partial J(W, b; x, y)}{\partial z_i^{(l+1)}} \frac{z_i^{(l+1)}}{W_{ij}^{(l)}} \quad (2.18)$$

又有

$$\frac{z_i^{(l+1)}}{W_{ij}^{(l)}} = \frac{\left( \sum_{j=1}^{S_l} W_{ij}^{(l)} f(z_i^{(l)}) \right)}{W_{ij}^{(l)}} = f(z_i^{(l)}) = a_i^{(l)} \quad (2.19)$$

于是可得

$$\frac{\partial}{\partial W_{ij}^{(l)}} J(W, b; x, y) = a_j^{(l)} \delta_i^{(l+1)} \quad (2.20)$$

综上，可以总结 BP 神经网络算法 **BP 神经网络算法**

- |   |                                     |
|---|-------------------------------------|
| 1 | 输入：训练输入 $x$ ，训练输出 $y$ ，学习率 $\alpha$ |
| 2 | <b>while</b> 未达到收敛条件                |

3 | 输入训练输入，训练输出，学习率

1. 初始化神经网络的权重与偏置
2. 对输入进行前向传播，得到除输入层外每一层  $(L_2, \dots, L_{n_l})$  的激活值  $a^{(2)}, \dots, a^{(n_l)}$
3. 计算各层残差：

(1) 对输出层（第  $n_l$  层）

$$\delta^{(n_l)} = -(y - a^{(n_l)}) \cdot (a^{(l)} \circ (1 - a^{(l)})) \quad (2.21)$$

(2) 对于  $l = n_l - 1, \dots, 2$  各层，可递推得出残差值

$$\delta^{(l)} = ((W^{(l)})^T \delta^{(l+1)}) \cdot (a^{(l)}) \quad (2.22)$$

(3) 计算损失函数对每一层权重的偏导数值

$$\nabla_{W^{(l)}} J(W, b; x, y) = \delta^{(l+1)} (a^{(l)})^T \quad (2.23)$$

(4) 更新参数

$$W^{(l)} = W^{(l)} - \alpha \nabla_{W^{(l)}} J(W, b; x, y) \quad (2.24)$$

4 | end

若为多分类问题，先对  $y$  进行 one-hot 处理得到  $p$  维向量  $(y_1, y_2, \dots, y_p)$ （假设  $y$  有  $p$  种取值），并将输出层的激活函数选为 softmax，即

$$a_i^{(n_l)} = f_s(z_i^{(n_l)}) = \frac{e^{z_i^{(n_l)}}}{\sum_j e^{z_j^{(n_l)}}} \quad (2.25)$$

并且代价函数使用交叉熵损失函数

$$J(W, b; x, y) = - \sum_i y_i \log a_i^{(n_l)} \quad (2.26)$$

则输出层残差为

$$\begin{aligned} \delta_i^{(n_l)} &= \frac{\partial J}{\partial z_i^{(n_l)}} \\ &= \sum_i \frac{\partial J}{a_i^{(n_l)}} \cdot \frac{\partial a_i^{(n_l)}}{\partial z_i^{(n_l)}} \\ &= \sum_i \frac{\partial - \sum_i y_i \log a_i^{(n_l)}}{a_i^{(n_l)}} \cdot \frac{\partial a_i^{(n_l)}}{\partial z_i^{(n_l)}} \\ &= - \sum_i \frac{y_i}{a_i^{(n_l)}} \frac{\partial a_i^{(n_l)}}{\partial z_j^{(n_l)}} \end{aligned} \quad (2.27)$$

当  $i = j$  时, 记  $e^{z_j^{(n_l)}} = e^A$ ,  $\sum_{k \neq j} e^{z_k^{(n_l)}} = e^B$ , 显然有  $e^A + e^B = \sum_i e^{z_i^{(n_l)}}$ , 于是

$$\begin{aligned}
\frac{\partial a_i^{(n_l)}}{\partial z_j^{(n_l)}} &= \frac{\partial a_j^{(n_l)}}{\partial z_j^{(n_l)}} \\
&= \frac{\partial \frac{e^A}{e^A + e^B}}{\partial A} \\
&= \frac{e^A(e^B + e^A) - e^{2A}}{(e^A + e^B)^2} \\
&= \frac{e^A e^B}{(e^A + e^B)^2} \\
&= \frac{e^A}{e^A + e^B} \frac{e^B}{e^A + e^B} \\
&= \frac{e^A}{e^A + e^B} \left(1 - \frac{e^A}{e^A + e^B}\right) \\
&= a_j^{(n_l)}(1 - a_j^{(n_l)})
\end{aligned} \tag{2.28}$$

### 2.3.3 激活函数

**sigmoid** sigmoid 函数表达式如下

$$f(x) = \frac{1}{1 + e^{-x}} \tag{2.29}$$

其图像如图 2.12 所示 sigmoid 激活函数考虑将输入值映射到  $(0, 1)$  的区间中, 该函

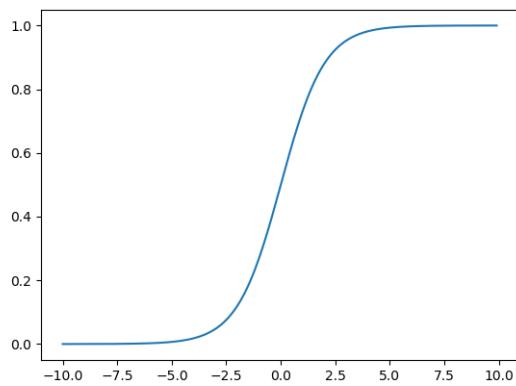


图 2.12 sigmoid 函数

数在定义域内连续，且导数大于 0。它也有较为简单的求导结果

$$f'(x) = f(x)(1 - f(x)) \quad (2.30)$$

但是在神经网络中，特别是对于层数较多的网络，通常不采用 sigmoid 作为激活函数，主要是因为其容易产生梯度消失的情况。当输入非常大或非常小的时候，其梯度趋近于 0，反向传播的过程中直接导致梯度无法传播，无法有效地调整权重。虽然做标准化可以让数据近似服从正态分布，但梯度消失仍有可能产生，在学习过程中可能会产生输入较大或较小的情况。或许这个问题可以用 batch-normalization 来缓解，但明显采取一种更佳的激活函数是较为可取的做法。

**ReLU** ReLU 函数表达式如下

$$f(x) = \max\{0, x\} \quad (2.31)$$

图像如图 2.13 其决定它有非常简单的求导结果

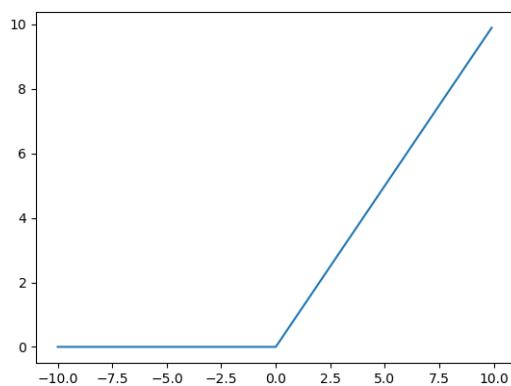


图 2.13 ReLU 函数

$$f'(x) = \begin{cases} 1, & x > 0 \\ 0, & x < 0 \end{cases} \quad (2.32)$$

ReLU 收敛能比 sigmoid 快的多，一方面其计算快，比起 sigmoid 函数的导数需要指数运算，ReLU 只需要做大小的比较。另一方面，其梯度经过多个层传播之后，

多数能够保持原汁原味，比起 sigmoid 会梯度消失要好得多。然而，ReLU 也有弱点，当  $x < 0$  时  $f(x)$  为 0，梯度为 0，这直接导致该神经元失活。因而在训练过程中，要注意取较小的学习率。

**Leaky ReLU** Leaky ReLU 是针对 ReLU 的弱点而改进的，其考虑用一个比较小的数去替代  $x < 0$  时的  $f(x) = 0$ ，即

$$f'(x) = \begin{cases} x, & x > 0 \\ ax, & x < 0 \end{cases} \quad (2.33)$$

图像如图 2.14 其求导结果为

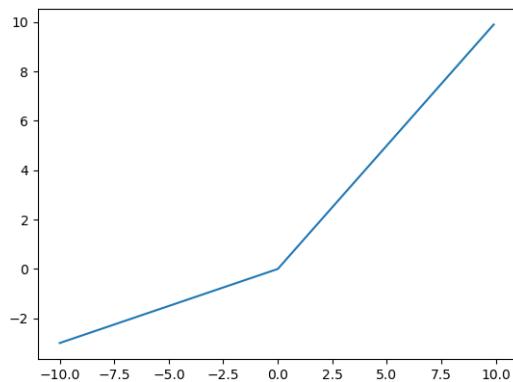


图 2.14 Leaky ReLU 函数

$$f'(x) = \begin{cases} 1, & x > 0 \\ a, & x < 0 \end{cases} \quad (2.34)$$

这个方法可以使  $x < 0$  处避免失活，但是额外引入了超参数  $a$ 。

**PReLU** PReLU 是针对 Leaky ReLU 的进一步优化，其考虑在反向传播过程中，也对  $a$  进行学习，从而避免引入超参数  $a$ 。一些实验<sup>[1]</sup> 证明这种优化能取到好的学习效果。

### 2.3.4 传统 BP 网络的应用

以上介绍的 BP 网络的算法以及较为传统的结构，我们想探究随着图像尺寸的变化（即输入大小）以及隐含层神经元。首先我们制备数据，通过 opencv 的方法，将输入图像归一化为同一大小，分别为  $64 \times 64$ ,  $96 \times 96$ ,  $128 \times 128$ ，学习率设置 0.03，优化函数采用 Mini-batch，以 8 个样本作为一个 batch，epoch 设为 600。首先考虑当隐含层分别设为 1000 和 500 时，图像大小为  $64 \times 64$  时，模型的训练准确率如图 2.15 从图中可以看出，隐含层为 1000 时比 500 好接近 5%，收敛速度

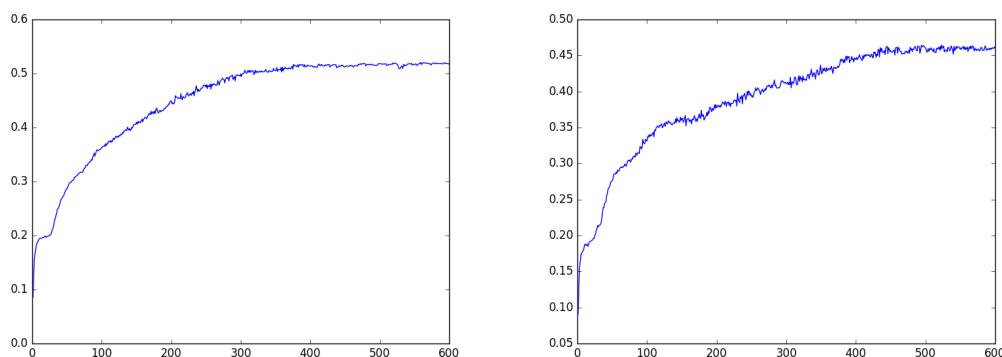


图 2.15 学习率为 0.03, 优化函数采用 MGD, 以 8 个样本作为一个 batch, epoch 设为 600, 图像大小为  $64 \times 64$  时, 隐含层为 1000 和 500 的准确率图

上，前者在 epoch 为 300 时就趋于稳定，后者在 epoch 为 450 时趋于稳定。其原因是隐含层 1000 时，其自由度比 500 大，随着参数的增加，更有可能得到偏差小的模型。从实验可以看出，前者相比于后者在达到较低偏差的同时，其方差也不会很大。

当隐含层分别设为 1000 和 500 时，图像大小为  $96 \times 96$  时，模型的训练准确率如图 2.16 从图中可以看出，隐含层 1000 与 500 在准确率上持平，为 50% 左右。由于随着图像的尺寸增加，过拟合的风险增大。而前者相比于后者有更低的模型复杂度，一定程度上抵制了过拟合。而过拟合的风险随着图像尺寸的增大而增大的现象，我们将在下图进一步看到：

当隐含层分别设为 1000 和 500 时，图像大小为  $128 \times 128$  时，模型的训练准确率如图 2.17 从图中可看出，当隐含层为 1000 时，其训练过程中准确率出现了大幅度的震荡，而且准确率收敛在了 45% 左右，而隐含层为 500 的模型相比隐含

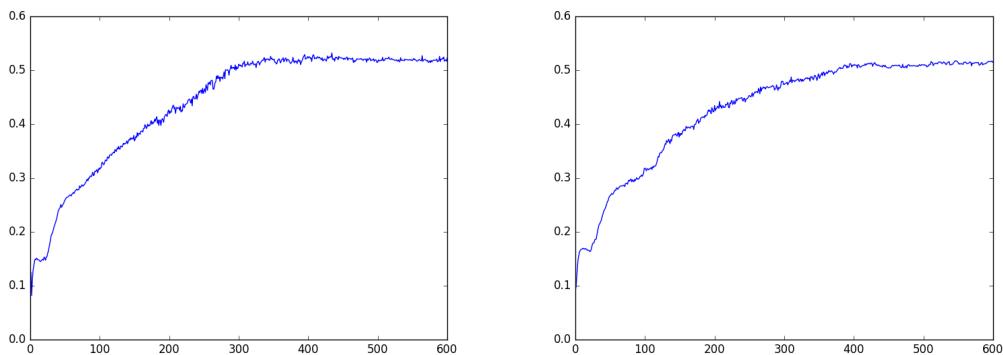


图 2.16 学习率为 0.03, 优化函数采用 MGD, 以 8 个样本作为一个 batch, epoch 设为 600, 图像大小为  $96 \times 96$  时, 隐含层为 1000 和 500 的准确率图

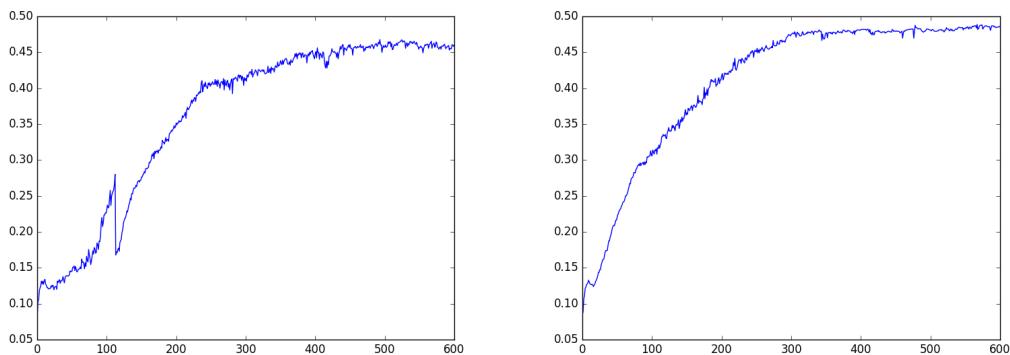


图 2.17 学习率为 0.03, 优化函数采用 MGD, 以 8 个样本作为一个 batch, epoch 设为 600, 图像大小为  $128 \times 128$  时, 隐含层为 1000 和 500 的准确率图

层为 1000 的模型的更加健壮, 而且准确率接近 50%, 比隐含层为 1000 的模型高了大概 4%。

综上, 我们可以得到各个模型的准确率表 2.3 可以看出, 在保证图像不要过

表 2.3 学习率为 0.03, 优化函数采用 MGD, 以 8 个样本作为一个 batch, epoch 设为 600 时, 不同数据集以及隐含层神经元数量所得到的准确率

	I64	I96	I128
1000	0.518188	<b>0.522655</b>	0.460115
500	0.460753	0.516273	0.48628

大而导致过拟合的条件下, 隐含层 1000 的模型比隐含层 500 的模型性能更优。

### 2.3.5 梯度下降方法

梯度下降法的选取能影响收敛速度与质量，它也是模型构成的一部分。在应用中一般有如下的梯度下降法可供选择

**批量梯度下降法** 批量梯度下降法 (Batch Gradient Descent) 考虑在计算了所有样本之后再对参数进行更新，即

$$W^{(l)} = \sum_{i=1}^m W^{(l)} - \alpha \nabla_{W^{(l)}} J(W, b; x^{(i)}, y^{(i)}) \quad (2.35)$$

由于通常训练的样本非常大，若在计算所有样本之后再进行参数更新，会让更新的速度减慢。另外，模型实现一般会采用矩阵运算，BGD 占的内存会非常多，从而影响计算速度。

**随机梯度下降法** 随机梯度下降法 (Stochastic Gradient Descent) 的想法与 BGD 截然不同，计算每一个样本之后便进行一次反向传播，对参数进行更新，即

$$W^{(l)} = W^{(l)} - \alpha \nabla_{W^{(l)}} J(W, b; x, y) \quad (2.36)$$

相比之下，SGD 的训练速度比 BGD 快得多，在 BGD 进行一次反向传播的时间内，SGD 已经进行过多次传播。但是在梯度下降过程中，SGD 容易出现震荡，由于单个样本并不能代表梯度最大的方向，也有可能导致解非最优的情况。

**小批量梯度下降法** 小批量梯度下降法 (Mini-batch Gradient Descent) 考虑了批量梯度下降法和随机梯度下降法的优缺点，并进行结合，考虑将数据集划分成多个含有较小数据的 batch，然后对这些 batch 分别采用 BGD。下面给出第  $i$  个 batch 的训练公式

$$W^{(l)} = \sum_{(x,y) \in b_i} W^{(l)} - \alpha \nabla_{W^{(l)}} J(W, b; x, y) \quad (2.37)$$

其中， $b_i$  代表当前 batch 所包含的训练样本  $(x, y)$  的集合。

**动量梯度下降法** 无论是 SGD 还是 MGD，即便 MGD 已在 SGD 上做了优化，在训练过程中仍可能会有振荡的风险。一种优化的方法是基于 SGD，在对参数  $W^{(t)}$  进行更新时，会考虑上一次的更新幅度，若是当前的梯度方向与上一次的相同，则能够加速收敛，反之则能抑制更新，这也是采用了动量的想法。其算法如下

```

1 输入：学习率  $\epsilon$ , 动量参数  $\alpha$ 
2  $t_{dw} = \alpha t_{dw} + (1 - \alpha)t_{dw}$ 
3  $W = W - \epsilon t_{dw}$ 

```

### 2.3.6 正则化与 dropout

机器学习中，常会发生过拟合的情况，通常引起这种情况的原因有数据量过小、维度过大、模型复杂度过大等，而此现象是方差过大且偏差太小所致。通常维度过大可采用特征选择的方法来降维，而模型复杂度可以用正则化项来限制。它是考虑在损失函数中添加能反映出模型复杂度的项。例如在神经网络中，下面的损失函数的第二项称为 L2 正则化

$$J(W, b; x, y) = -\sum_i y_i \log a_i^{(n)} + \lambda \sum_w w^2 \quad (2.38)$$

我们可以把损失函数看出是由偏差衡量项（第一项）和方差衡量项（第二项）组成，其本质是偏差、方差权衡，权衡通过  $\lambda$  来实现。

除了 L2 正则化之外，常用的还有 L1 正则化，为如下形式

$$J(W, b; x, y) = -\sum_i y_i \log a_i^{(n)} + \lambda \sum_w |w| \quad (2.39)$$

将正则化方法加入到神经网络中，设使用 I96 数据集，隐含层神经元个数为 500，学习率设置 0.03，优化方法采用 MGD，以 8 个样本作为一个 batch，epoch 设为 600。我们依次测试当正则化系数为 0.1, 0.01, 0.001 和 0.0001 时的模型差别，结果如图 2.18

其结果如表 2.4 可以看出，只有一层隐含层的 BP 网络对于正则化系数很敏感。当取 0.1 和 0.01 时，模型太过简单，以至于得不到好的模型，当将正则化系数

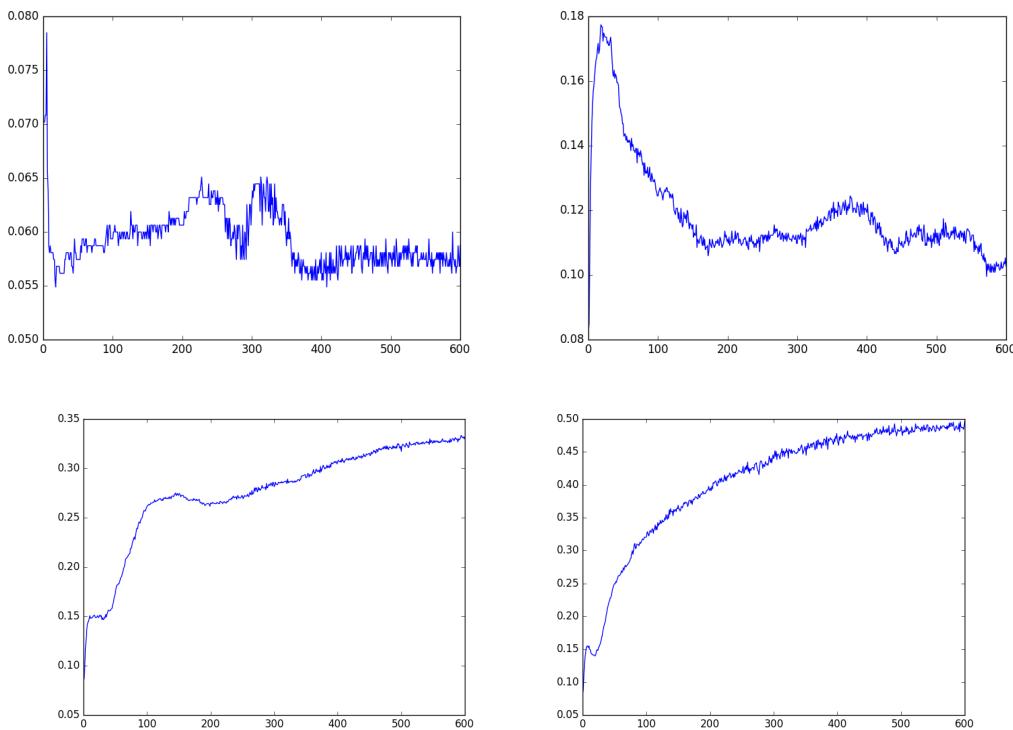


图 2.18 使用 I96 数据集，隐含层神经元个数为 500，学习率为 0.03，优化方法为 MGD，以 8 个样本作为一个 batch，epoch 设为 600 时，正则化系数为 0.1,0.01,0.001 和 0.0001 时准确率图（按左上，右上，左下，右下的顺序）

表 2.4 使用 I96 数据集，隐含层神经元个数为 500，学习率为 0.03，优化方法为 MGD，以 8 个样本作为一个 batch，epoch 设为 600，正则化系数为 0.1,0.01,0.001 和 0.0001 时准确率表

正则化系数	0.1	0.01	0.001	0.0001
准确率	0.0587109	0.102744	0.331844	0.49649

放宽到 0.0001 时，可以接近 50%，但是，过小的，甚至是很接近 0 的正则化系数，事实上与没有设置正则化的模型性能接近（在没有设置正则化参数为 0， $96 \times 96$  的图片大小，隐含层节点为 500 时，准确率为 0.5163），这是由 BP 网络模型复杂度不够大造成的。相对而言，正则化用于复杂的模型效果会更好，例如卷积神经网络。

神经网络中，除了加入正则化项之外，还能考虑在每次训练中，让所有神经元以一定概率  $p$  失活，封闭该神经元的输出，即将这部分的神经元输出设置为 0。此方法称为 dropout。因而在每次训练中，网络结构都不一样，在降低模型复杂度的同时，也是对于多个模型的集成。在验证时，则所有的神经元处于激活状态，即不设置 dropout。其示意图如 2.19

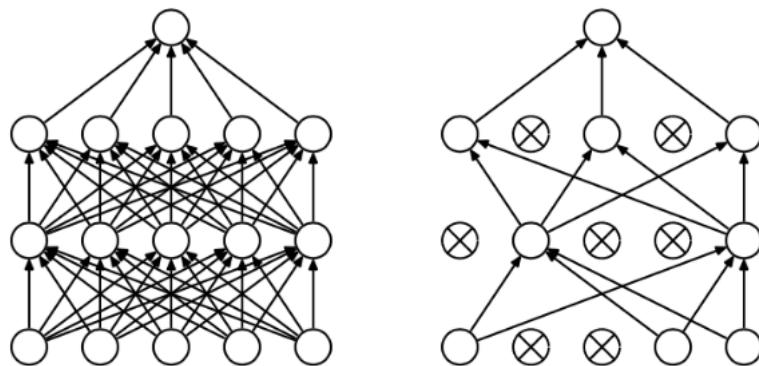


图 2.19 dropout 训练时工作原理示意图

尝试在神经网络中加入 dropout，依旧使用 I96 数据集，隐含层神经元个数为 500，学习率设置为 0.03，优化方法采用 MGD，以 8 个样本作为一个 batch，epoch 设为 600。分别设置 dropout 为 0.1,0.3,0.5,0.7，其结果如图 2.20 所示

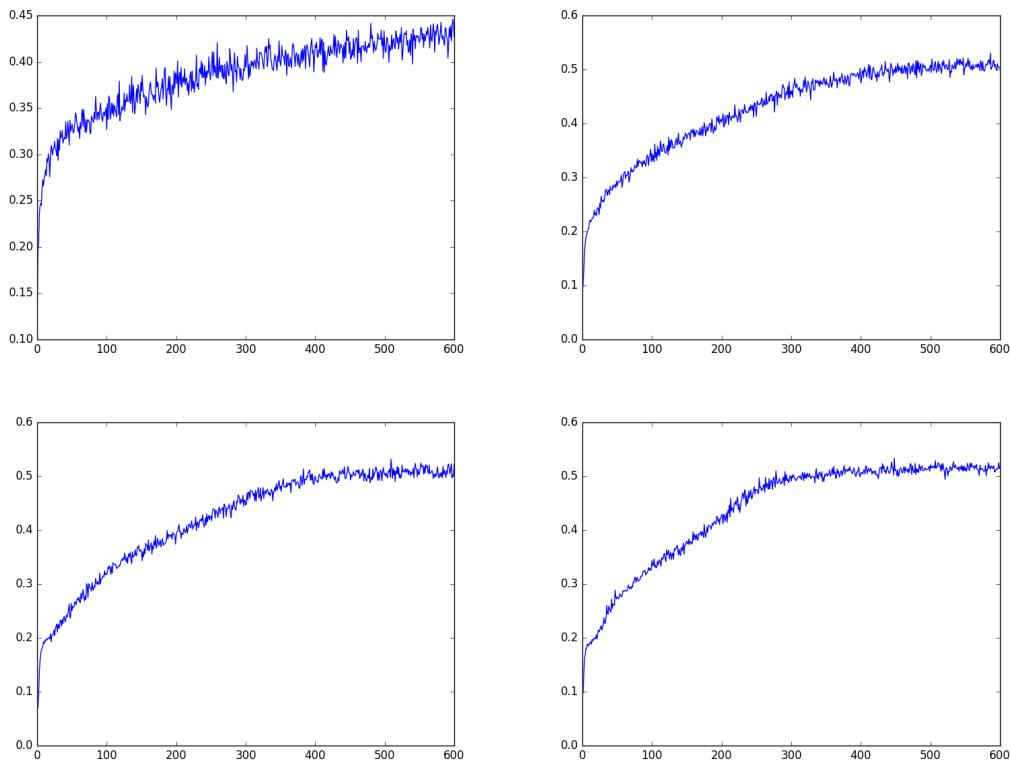


图 2.20 使用 I96 数据集，隐含层神经元个数为 500，学习率设置为 0.03，优化方法采用 MGD，以 8 个样本作为一个 batch，epoch 设为 600。分别设置 dropout 为 0.1,0.3,0.5,0.7 的准确率图（按左上，右上，左下，右下的顺序）

上述模型的准确率如表 2.5 从曲线形态可见，当 dropout 的概率  $p$  越大时，曲线更加稳定，并没有出现剧烈震荡的情况，相比于传统的 BP 网络或者加入正

表 2.5 使用 I96 数据集，隐含层神经元个数为 500，学习率设置为 0.03，优化方法采用 MGD，以 8 个样本作为一个 batch，epoch 设为 600。分别设置 dropout 为 0.1,0.3,0.5,0.7 的准确率表

dropout rate	0.1	0.3	0.5	0.7
准确率	0.42693	0.50415	0.52202	0.51691

则化的 BP 网络，其准确率曲线形态也更加稳健。从准确率来看，同样的网络结构，有加入 dropout 的网络比没有 dropout 的网络能够达到更高的准确率（其他条件相同时，dropout 的概率  $p$  为 0.5 时准确率为 0.52202，没有 dropout 时准确率为 0.516273），这是由于加入 dropout 之后，网络具有防止过拟合的性能。一般情况下，dropout 加入在全连接层。若是卷积神经网络，则 dropout 将加入到卷积神经网络的全连接层中，而不加入到卷积层中。在下面的卷积神经网络的探究中，也将在全连接层中加入 dropout 方法，并设置 dropout 的概率  $p$  为 0.5。

### 2.3.7 卷积神经网络概述

卷积神经网络的特点在于能够提取出一个图像中的各种特征。其原理为自然图像的一部分的统计特性与其他部分是一样的。也就是说在这一部分学习的特征也能用在另一部分上，所以对于这个图像上的所有位置，我们都能使用同样的学习特征（权值）。我们提取一种特征用一种卷积核，卷积核为图 2.21 左边图像黄色部分，卷积核的权值为黄色部分右下红色字体，右边图像为卷积后的图像矩阵。设大

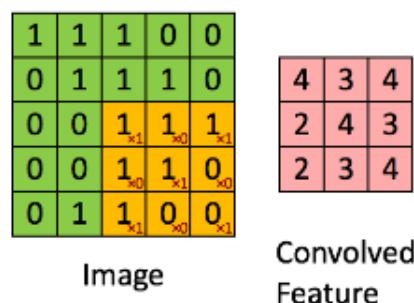


图 2.21 卷积原理图示

矩阵的大小为  $d \times d$ ，利用大小为  $m \times m$  的卷积核可以得到特征提取降维后的大小为  $(d - m + 1) \times (d - m + 1)$  的矩阵。这个过程为一个特征的提取。在卷积的过程中，从原图像 (Image) 矩阵  $I$  生成的卷积特征矩阵  $C$  (Convolved Feature) 中的每个元

素为:

$$C_{ij} = \sum_{u=1}^m \sum_{v=1}^m w_{uv} I_{i+u-1, j+v-1} \quad (2.40)$$

其中,  $i, j \in (d - m + 1)$  对于卷积特征矩阵 (Convolved feature) 我们下一步进行池化。池化的目的是对图像不同位置进行聚合统计来描述大的图像。聚合统计可以通过计算一个区域上某个特定特征的平均值或者最大值, 这样可以降低更多的维度以及不容易过拟合。如果选择图像中连续的范围作为池化区域, 并且只是池化重复的隐藏单元产生的特征, 那么这些池化单元具有平移不变性。这就意味着即使图像经历了一个小的平移之后依然会产生相同的池化特征。池化过程如图 2.22 我们

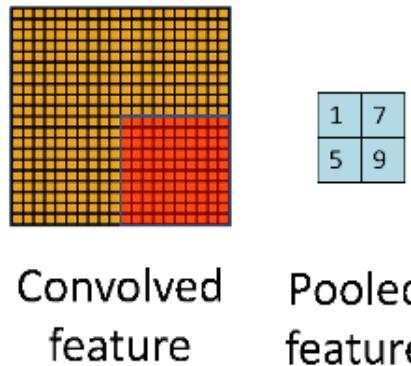


图 2.22 池化原理图示

叫上图左图红色部分为一个池, 并且通常取能够将卷积特征矩阵平均划分的大小的池。池化后我们得到池化特征矩阵  $P$ (Pooled feature), 我们设卷积特征图像为长宽都为  $c$  的矩阵, 则池长宽设为  $p$ , 若为最大池化则  $P$  的元素为:

$$P_{ij} = \max_{u \in [1, p], v \in [1, p]} \{C_{u+(i-1) \times (p+1), v+(j-1) \times (p+1)}\} \quad (2.41)$$

其中,  $i, j \in [1, \frac{c}{p}]$ 。若采用平均池化, 则  $P$  的元素为

$$P_{ij} = \frac{1}{p^2} \sum_{v=1}^p \sum_{u=1}^p C_{u+(i-1) \times (p+1), v+(j-1) \times (p+1)} \quad (2.42)$$

其中,  $i, j \in [1, \frac{c}{p}]$ 。事实上, 在设置卷积核时, 一般将其设置为四维, 各个维度分别为: 卷积核长、卷积核宽、上一层的图像深度, 卷积核个数。另外, 对于一些深

度学习的任务，是需要重复卷积很多次，为了实现这一目的，需要确保卷积之后图像长宽不变，于是在卷积之前通常在图像周围补足够个数的 0，以扩大图像的尺寸，卷积时步长为 1，使得卷积之后的图像与原来的图像尺寸相同。在 AlexNet, VGGNet, Inception 以及本论文所构造的卷及神经网络中，在卷积时都采取这种方法来保证卷积后与卷积前图像尺寸大小相同，因而图像尺寸的削减只通过池化层。

卷积神经网络其实可以包含两个大的部分，分别为特征提取层与分类器层。特征提取层包含若干个卷积层和池化层。在特征提取层中，只需要训练卷积核，而卷积层的共享参数与卷积核的属性，相比于全连接神经网络，参数更少，且抓住了图像的特征。特征提取层的输出需要转化之后，才能接入分类器层，一般的做法是将输出拉长为向量，而分类器层一般是用全连接的神经网络，最后接入 softmax 层，与标签计算损失函数，进而反向传播。图 2.23 是一种卷积网络结构，其对应的任务是手写数字识别。

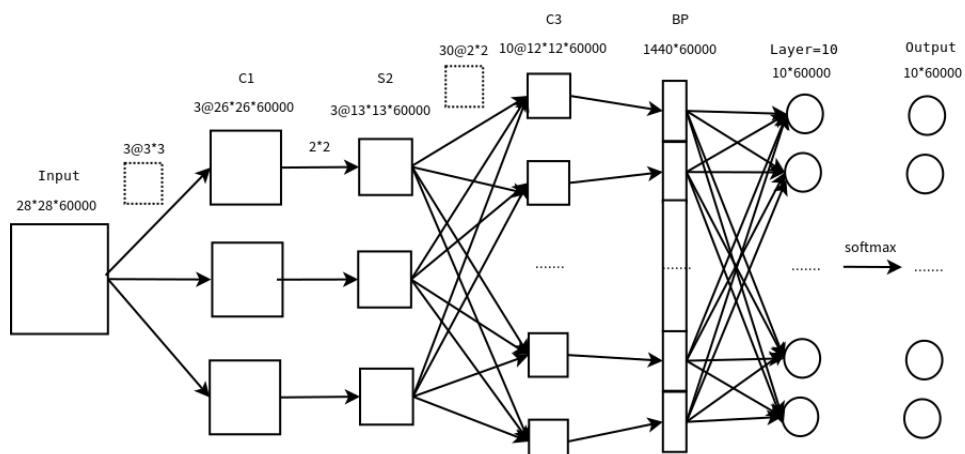


图 2.23 一种 CNN 用于手写数字识别的结构

### 2.3.8 经典 CNN 模型

AlexNet 结构上由 8 层隐含层组成，前五层为特征提取层，后三层为分类器层，用于做图像分类。其具体的结构如图 2.24：AlexNet 当年提出来用已解决 ImageNet 的分类问题，对于  $224 \times 224$  像素的三通道照片，第一层使用  $11 \times 11 \times 3 \times 96$  的卷积核；第二层使用  $5 \times 5 \times 96 \times 256$  的卷积核，并进行最大池化；第三层使用  $3 \times 3 \times 256 \times 384$  的卷积核；第四层使用  $3 \times 3 \times 384 \times 384$  的卷积

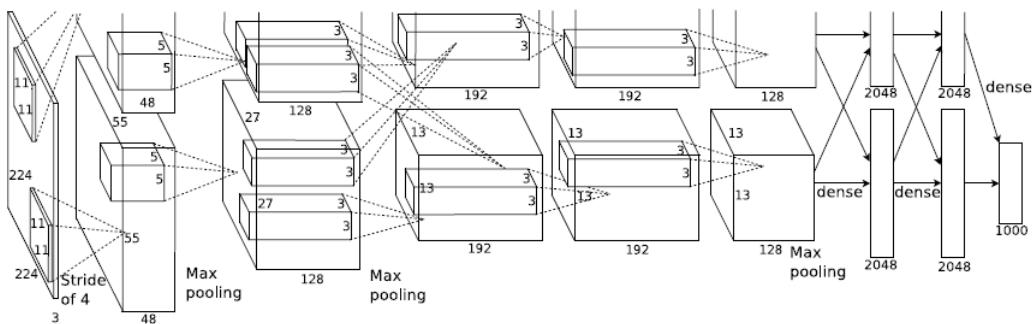


图 2.24 AlexNet 结构。需注意的是，隐含层计算时分为上下部分计算，实际上是一个分布式计算的想法

核；第五层使用  $3 \times 3 \times 384 \times 256$  的卷积核；之后连接全连接层，第六、七层都为 4096 个神经元，第八层则使用 softmax。AlexNet 的创新点在于激活函数采用了 ReLU 与 dropout。

从网络设计的思路上看，VGGNet 继承了 AlexNet 的思路，沿用 ReLU 激活函数与 dropout，并尝试建立层数更多，深度更深的网络。其有一个很重要的特点是，VGGNet 的每个卷积层并不是只做一次卷积操作，而是连续卷积 2 到 4 次，并且每次卷积统一采用  $3 \times 3$  的卷积核进行卷积，这可以起到降低参数数量以及让运算速度更快。表 2.6 是 AlexNet 以及两种 VGGNet 在 ImageNet 中取得很好效果的结构，分别是 16 层版本和 19 层版本。

单纯从 AlexNet, VGG16, VGG19 的特征提取层进行比较，我们可以计算出参数个数，这里我们只计算特征提取层的参数个数，如表 2.7 可以看到，VGGNet 的参数数量是 AlexNet 的至少 4 倍，足够大的参数空间决定了 VGGNet 有足够的表达能力，能够提取出更多的特征，然而训练所需的时间与计算量相当大，为了弥补这一点不足，也提出了迁移学习的方法，在本论文不做相关讨论。

Inception 的想法与 AlexNet 和 VGGNet 完全不同。AlexNet、VGGNet 是通过叠加层数，让网络具有足够的深度，形式上看，不同的卷积层通过串联的方式结合在一起，而 Inception 采用不同的卷积层进行卷积，再通过并联的方式结合在一起，而非 AlexNet 或 VGGNet 中的简单卷积，该结构称为 Inception 模块，其示意图如 2.25 对于输入，Inception 首先用不同尺寸，卷积核数目较少的卷积核对输入矩阵进行卷积，卷积方式采用补 0 后卷积，以保证卷积后尺寸不变。从不同的

表 2.6 AlexNet,VGG16,VGG19 结构。其中  $n \times \text{conv}X-Y$  表示过滤器的边长为 X, 卷积核个数 Y, 连续 n 层; max pooling 代表最大池化层, 步长为 2; fc m 代表全连接层, m 个神经元节点; softmax 代表 softmax 层。

AlexNet	VGG16	VGG19
conv11-96	$2 \times \text{conv}3-64$	$2 \times \text{conv}3-64$
max pooling	max pooling	max pooling
conv5-256	$2 \times \text{conv}3-128$	$2 \times \text{conv}3-128$
max pooling	max pooling	max pooling
$2 \times \text{conv}3-384$	$3 \times \text{conv}3-256$	$4 \times \text{conv}3-256$
conv3-256	max pooling	max pooling
max pooling	$3 \times \text{conv}3-512$	$4 \times \text{conv}3-512$
	max pooling	max pooling
	$3 \times \text{conv}3-512$	$4 \times \text{conv}3-512$
	max pooling	max pooling
fc 4096	fc 4096	fc 4096
fc 4096	fc 4096	fc 4096
fc 1000	fc 1000	fc 1000
softmax	softmax	softmax

表 2.7 AlexNet,VGG16,VGG19 参数数量

	AlexNet	VGG16	VGG19
参数数量	3,745,824	14,710,464	19,982,016

卷积核卷积之后的结果进行按第四个维度 (即卷积核所在维度) 进行拼接, 则可以得到一个更深的矩阵。比起 VGGNet, 在接受相同的输入并返回相同尺寸的输出时, Inception 所需要的参数更少。假设对于  $224 \times 224 \times 128$  的图片输入, 返回是  $224 \times 224 \times 128$  的输出, VGGNet 在该层需要  $3 \times 3 \times 128 \times 128$  的卷积核, 则 VGGNet 在该层需要 147456 参数; 而 Inception 若采用图 2.25, 则考虑将 128 个卷积核分成 3 份, 则卷积核分别为  $1 \times 1 \times 128 \times 42$ ,  $3 \times 3 \times 128 \times 44$ ,  $5 \times 5 \times 128 \times 42$ , 而 Inception 中为了避免宽度过大的卷积核的出现, 常采用  $a \times 1 \times b \times d$  与  $1 \times a \times d \times c$  做串联来代替  $a \times a \times b \times c$ , 这种做法提高了运算速度, 降低了参数个数, 一定程度上降低了过拟合的风险。我们可以把这种方法运用在  $5 \times 5 \times 128 \times 42$  的卷积核上, 于是可以分解为  $5 \times 1 \times 128 \times 70$  和  $1 \times 5 \times 70 \times 42$  两个卷积核, 综上, Inception

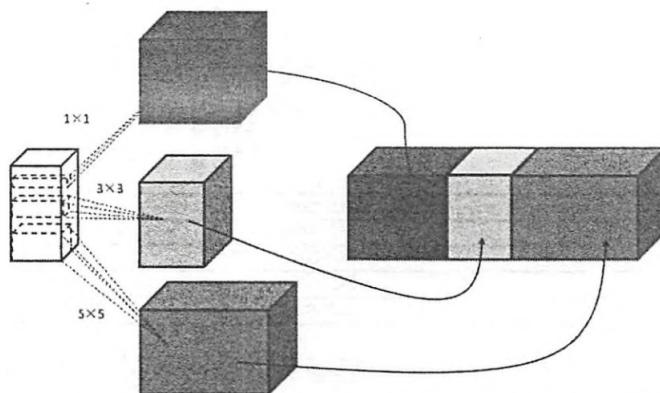


图 2.25 Inception 模块示意图

在该层需要的参数为 115564。事实上，Inception 是通过增加卷积核种类来减少单种卷积核数目，在一定参数的限制下可以让多种卷积核去参与学习。

### 2.3.9 CNN 的应用

在卷积神经网络的实验中，为了保证图片拥有足够的信息量，因而使用 I128 数据集，为了训练能顺利进行，学习率设置为 0.001，优化方法采用 Mini-batch 动量梯度下降法，以 100 个样本作为一个 batch，epoch 设为 600。表 2.8 中的四种卷积网络结构由 AlexNet 和 VGGNet 修改的网络，网络修改时保留 VGGNet 所具有的卷积核大小为  $3 \times 3$ ，且卷积有一定深度的特点，但由于训练数据较少，因而设置比 VGGNet 浅的网络深度，由于本问题是 13 个类别的分类问题，类别数比 ImageNet 的类别数要小得多，因而将 VGGNet 中分类器层的三个全连接层替换为一个卷积层，分别编号为 CNN-A，CNN-B，CNN-C，CNN-D。表 ?? 中的两种网络结构都采用了 Inception 的思想。由于数据量小，为了防止过拟合，采用了  $1 \times 1$ ， $3 \times 3$ ， $1 \times 5$ ， $5 \times 1$  五种卷积核。两种网络结构只有在分类器层上面有区别，第一种采用一层全连接层，神经元个数为 1000；第二种采用两层全连接层，神经元个数分别为 1000 和 100。两种网络结构分别标号为 CNN-E，CNN-F，如图 ??, ??。

表 2.8 CNN-A,CNN-B,CNN-C,CNN-D 的结构

model	CNN-A	CNN-B	CNN-C	CNN-D
网络结构	2×conv3-64	1×conv3-64	1×conv3-64	1×conv3-64
	max pooling	max pooling	max pooling	max pooling
	2×conv3-128	1×conv3-96	1×conv3-96	1×conv3-96
	max pooling	max pooling	max pooling	max pooling
	2×conv3-256	2×conv3-128	1×conv3-128	1×conv3-128
	max pooling	max pooling	max pooling	max pooling
	2×conv3-512	1×conv3-256	1×conv3-256	1×conv3-256
	max pooling	max pooling	max pooling	max pooling
	2×conv3-512		1×conv3-512	2×conv3-512
	max pooling		max pooling	max pooling
	fc 1000	fc 1000	fc 1000	fc 500
	softmax	softmax	softmax	softmax

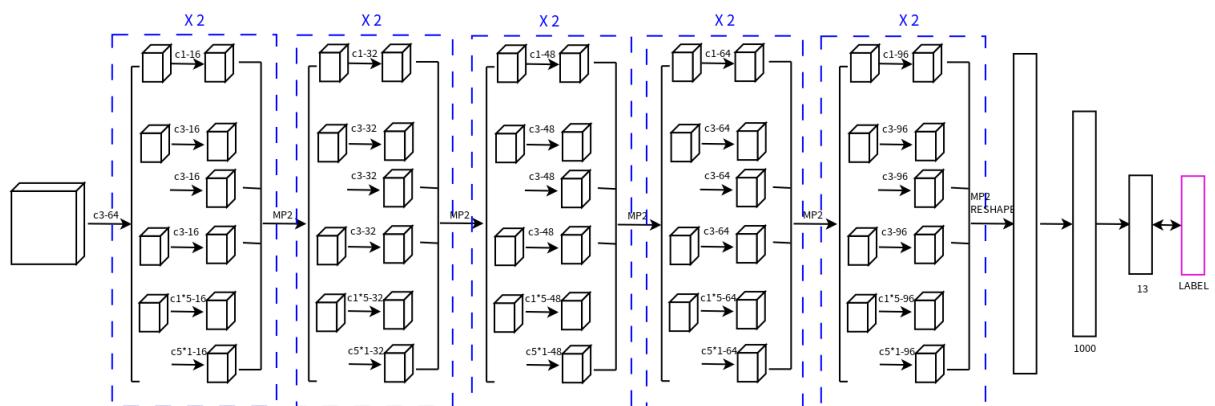


图 2.26 CNN-E 的结构

采用 CNN-A,CNN-B,CNN-C,CNN-D,CNN-E,CNN-F 的结构，使用 I128 数据集，学习率设置为 0.001，优化方法采用 Mini-batch 动量梯度下降法，正则化参数为 0.0001，以 100 个样本作为一个 batch，epoch 设为 600。结果如图 2.9 所示

从结果可以看出，CNN-C 达到了最高的准确率，该模型在模型复杂度和过拟合风险之间找到了权衡，其适当数量的卷积核个数很好的提取了图像的特征，全连接层为 1000 个神经元，能起到良好的分类其作用。CNN-E 和 CNN-F 都采用了 Inception 模块构建网络，但取得的效果不如从 AlexNet 和 VGGNet 改造而来的

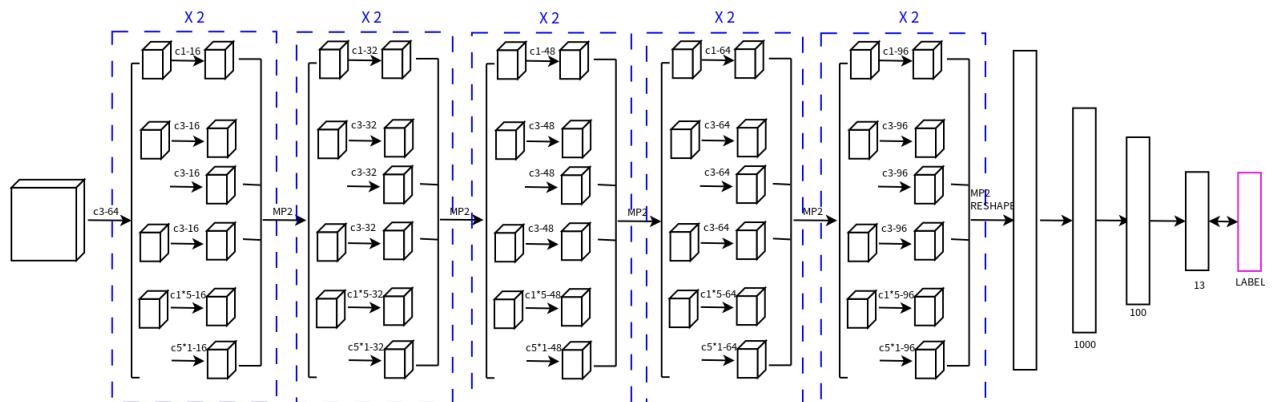


图 2.27 CNN-F 的结构

表 2.9 CNN-A,CNN-B,CNN-C,CNN-D,CNN-E,CNN-F 的准确率

模型	CNN-A	CNN-B	CNN-C	CNN-D	CNN-E	CNN-F
所用数据集	I128					
学习率		0.01				
优化函数			MGD+ 动量梯度下降法			
正则化参数			0.0001			
准确率	0.652202	0.664327	0.673899	0.659860	0.406509	0.411615

CNN-A, CNN-B, CNN-C, CNN-D。

## 2.4 NN+X

### 2.4.1 改进思路

计算机视觉中的目标检测问题是训练模型，给予该模型一张图片，模型将图片内特定物体框出，其效果如 2.28 训练模型所使用的数据中，输入数据为原始图片，输出为标签区域坐标（label region）以及该边框所框的物体类别（label）。在该领域上，常采用 RCNN（Region Convolutional Neural Network）去建立模型。RCNN 算法流程图如 2.30。RCNN 通过图像处理方法生成多个候选框（Candidate region），并对候选框做缩放，得到同样尺寸的图像，之后放入特征提取层中提取特征，再拉长为列向量。此时，RCNN 需要两轮训练，一轮是针对 softmax 层的（如图中 PATH 1），该层用于微调候选框；另一层是针对 SVM 的（如图中 PATH 2），用于该框所属类别的分类。由于 SVM 是二分类器，因而还使用了 OvR 策略，

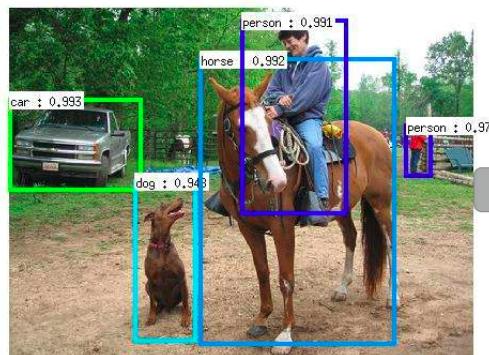


图 2.28 RCNN 效果

构建和类别数一样多的分类器个数。训练 softmax 层和训练 SVM 的标签是有些许不同，这是由 RCNN 所要解决的问题决定的，在此处并不进行讨论。在 RCNN 中，由于直接采用 softmax 会比采用 SVM 精度低，而且 SVM 适用于少样本的训练，所以采用 SVM 替代了 softmax。

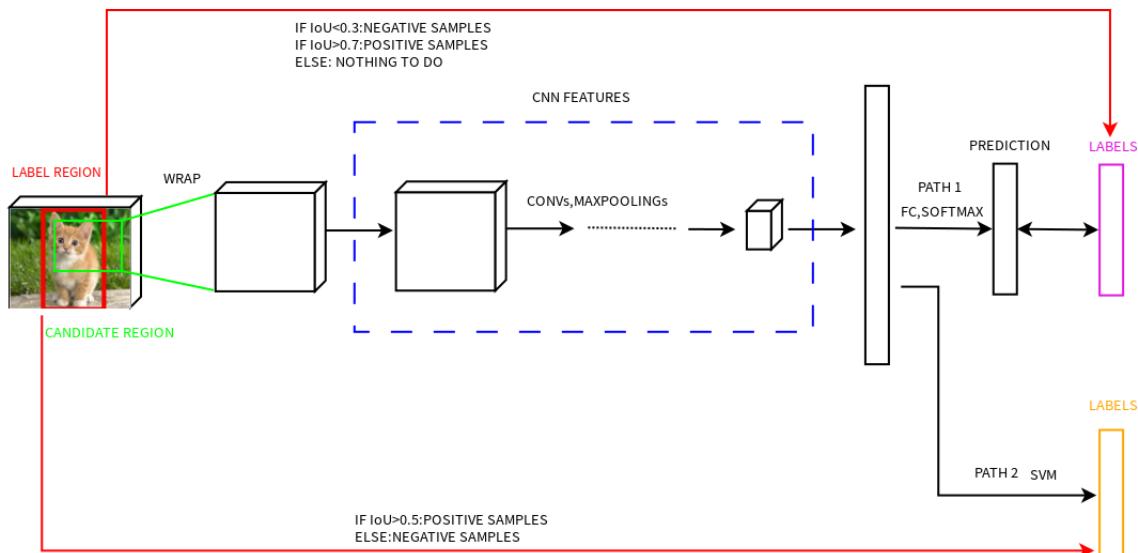


图 2.29 RCNN 算法流程

从 RCNN 带来的想法是神经网络与传统机器学习模型的融合。由于本问题是一个分类问题，卷积神经网络强大之处在于提取并学习图像特征，从而得到远低于图像维度的特征向量，而 SVM 在小样本的分类问题中有很好的性能。若是采用卷积神经网络提取特征得到特征向量后，采用 SVM 分类器分类可能能够提升模型的性能，本文的想法是神经网络带 softmax 进行训练，在调整完网络之后，采用某种分类算法（记为算法 X）去替换 softmax 层，并训练算法 X，算法流程

如图 ??。为了探究此种替换是否有提升，论文也将探讨多种神经网络：BP 神经网络（选取表 2.31 的 BP 神经网络结构）、VGGNet 所更改的网络（选取表 2.8 的 CNN-A 到 CNN-D 的结构）、Inception 结构（选取图 ?? 和 ?? 的 CNN-E 和 CNN-F 的结构），与分类器算法 X：SVM，决策树，随机森林的组合。

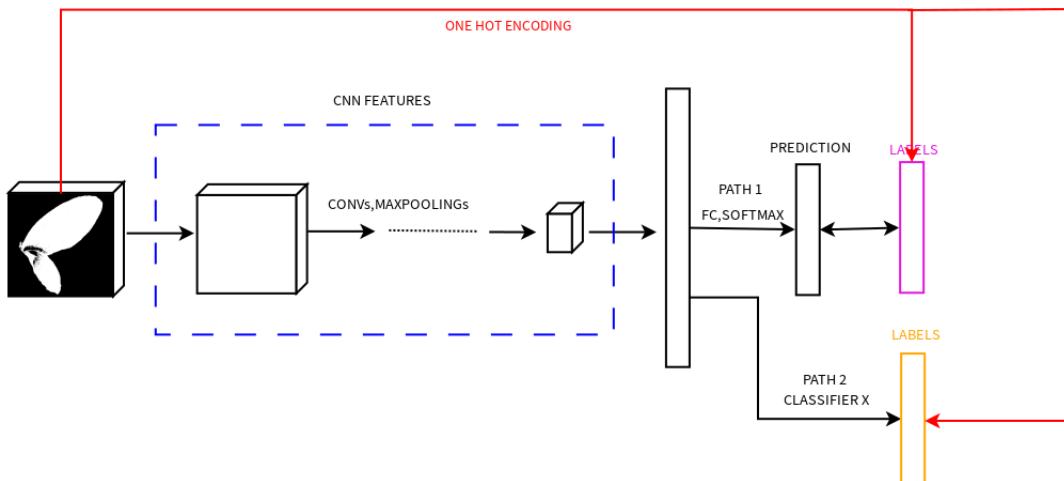


图 2.30 CNN+X 模型

表 2.10 BP-A,BP-B,BP-C,BP-D 模型概况

model	BP-A	BP-B	BP-C	BP-D
隐含层	1000	1000	500	500
所用数据集	I64	I96	I96	I96
学习率	0.03	0.03	0.03	0.03
优化函数	MGD	MGD	MGD	MGD
正则化参数	0	0	0	0.0001
准确率	0.518188	0.522655	0.516273	0.49649

## 2.4.2 BP 神经网络 +X

为了对比改进后模型的性能，首先要排除 SVM 在 I64, I96, I128 就有非常好的性能的可能性（比如超越卷积神经网络的准确率）。先在 I64, I96, I128 上进行 SVM 的分类，其结果如图 2.11 其中，多项式核 svm 能够达到较高的准确率。

接下来，在 BP-A 到 BP-D 中，将 softmax 换成 SVM，有表 2.12

为了更为直观展现结果，表 2.12 对应的图 2.31 如下

表 2.11 SVM 在 I64, I96, I128 上的分类结果准确率。其中，svm-k, k 代表核函数类型

数据集	svm-linear	svm-poly	svm-rbf	svm-sigmoid
I64	0.361199	0.524569	0.486280	0.081685
I96	0.388641	0.534142	0.507339	0.086790
I128	0.373325	0.559668	0.507977	0.356733

表 2.12 第一列为原始的 BP-A,BP-B,BP-C,BP-D 准确率，第二列为 svm 在 I64,I96 上的准确率，第三到第六列为 BP-A,BP-B,BP-C,BP-D 中将 softmax 层换成 SVM，并依次选取 linear,poly,rbf,sigmoid 核后的准确率

	softmax	svm-poly	bpsvm-linear	bpsvm-poly	bpsvm-rbf	bpsvm-sigmoid
BP-A	0.518188	0.524569	0.538609	0.576260	0.587109	0.081685
BP-B	0.522655	0.534142	0.530951	0.577537	0.590938	0.075303
BP-C	0.516273	0.534142	0.507339	0.541799	0.580728	0.066369
BP-D	0.49649	0.534142	0.529675	0.572431	0.594129	0.356733

可以看出，当采用高斯核函数的 SVM 替换 BP 神经网络的 softmax 层，能够显著提高模型效果。相比与原来带有 softmax 层的 BP 神经网络，其准确率提高了 6.4% 到 9.7% 左右，相比于原来带多项式核函数的 SVM，其准确率提高了 4.7% 到 6.3% 左右。从结果上看，似乎 BP 神经网络与 SVM 的结合有成效，下面将用 CART 树和随机森林来进一步探究 BP 神经网络 +X 的有效性。下面使用 CART 树代替 softmax，有结果如表 2.13，为了更为直观展现结果，表 2.13 对应的条形图 2.32 如下

表 2.13 第 1 列为原始的 BP-A,BP-B,BP-C,BP-D 准确率，第 2 列为 bpsvm-rbf 准确率，第 3 到 6 列为用 CART 树代替 softmax 的准确率，其中 mdh 代表最大深度。

model	softmax	bpsvm-rbf	bpCART-mdh:5	bpCART-mdh:10	bpCART-mdh:15	bpCART-mdh:20
BP-A	0.518188	0.587109	0.414167	0.417358	0.408424	0.411615
BP-B	0.522655	0.590938	0.416720	0.398851	0.387364	0.391078
BP-C	0.516273	0.580728	0.353542	0.337588	0.325463	0.327378
BP-D	0.49649	0.594129	0.395662	0.398851	0.389917	0.391193

当 X 为 CART 树时，效果并不令人满意，有可能是树模型的弊端造成的，而非是 BP 神经网络 +X 的结构所带来的问题。为了克服树的弊端，选取随机森林，对树模型进行集成，可大大提高树模型的性能。下面讨论 X 为随机森林时，BP 神

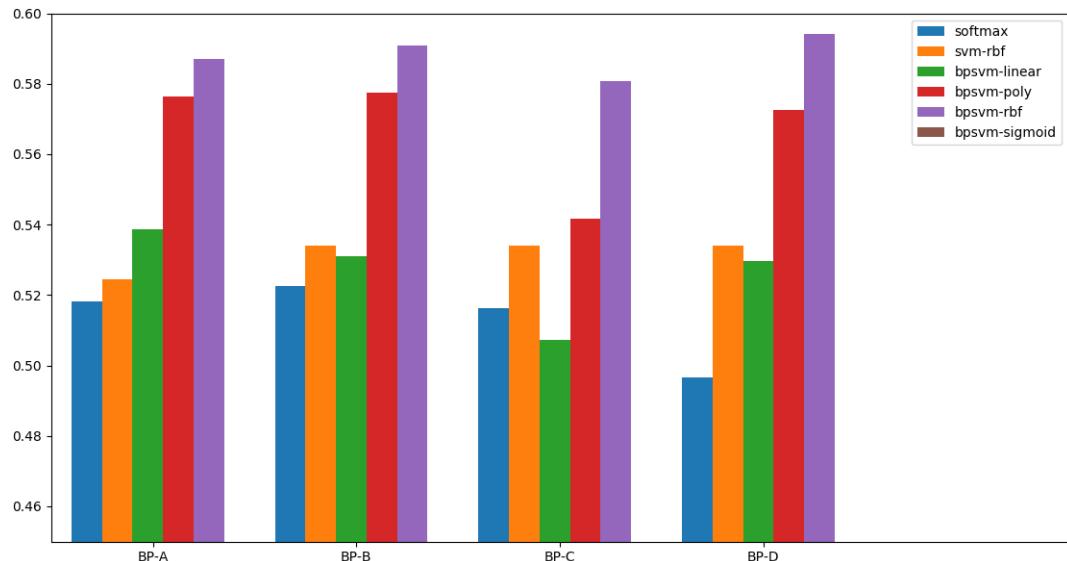


图 2.31 原始的 BP-A,BP-B,BP-C,BP-D,SVM, 与用 SVM 替换 BP-A,BP-B,BP-C,BP-D 中 softmax 层所得的准确率图

经网络 +X 的模型性能。结果如表 2.14, 对应图 2.33

表 2.14 第 1 列为原始的 BP-A,BP-B,BP-C,BP-D 准确率, 第 2 列为 nsvm-rbf 准确率, 第 3 到 6 列为用随机森林代替 softmax 的准确率, 其中, n 代表随机森林包含的树桩个数。

model	softmax	bpsvm-rbf	bprf-n:20	bprf-n:50	bprf-n:80
BP-A	0.518188	0.587109	0.544352	0.552010	0.573070
BP-B	0.522655	0.590938	0.530313	0.559668	0.574346
BP-C	0.516273	0.580728	0.504786	0.534780	0.555839
BP-D	0.49649	0.594129	0.523293	0.561583	0.555839
model	bprf-n:110	bprf-n:140	bprf-n:170	bprf-n:200	bprf-n:230
BP-A	0.574346	0.569879	0.577537	0.580089	0.574984
BP-B	0.569879	0.586471	0.596043	0.583918	0.575622
BP-C	0.545629	0.557754	0.550734	0.562221	0.569241
BP-D	0.560944	0.573070	0.576899	0.580089	0.579451

当 X 为随机森林时, 其体现出了集成学习的优势, 准确率相对于 CART 树, 准确率高出 14% 以上, 并且在 BP-B 的 170 个树桩的随机森林上, 准确率达到 59.6%, 超越 bpsvm-rbf 的 59.1% 的准确率, 其性能比 bpsvm-rbf 稍低, 相比与原

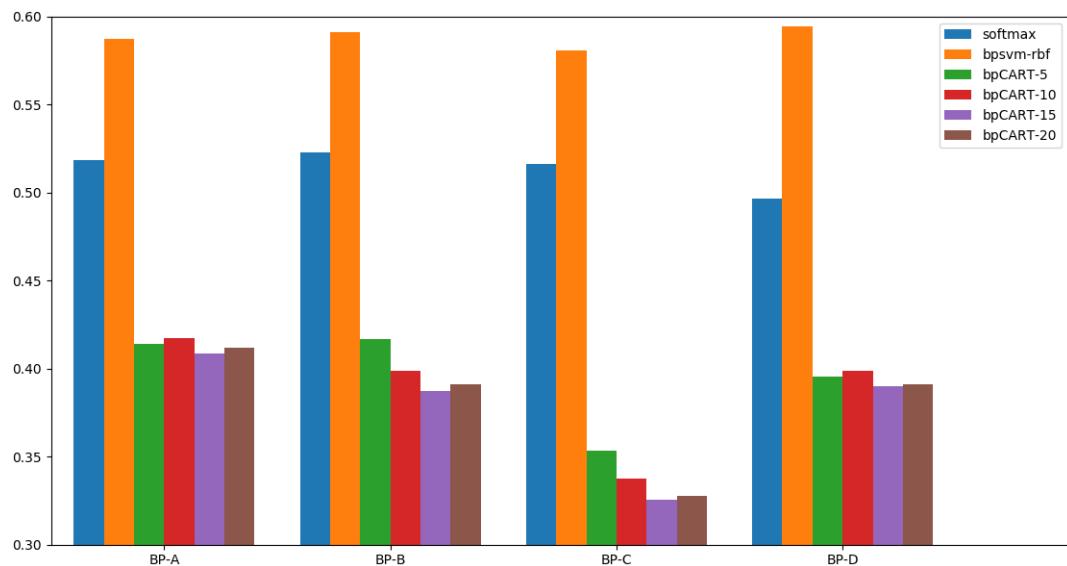


图 2.32 原始的 BP-A,BP-B,BP-C,BP-D,bpsvm-rbf, 与用不同深度的 CART 替换 softmax 层所得的准确率图

来带有 softmax 层的 BP 神经网络，其准确率提高了 4.6% 到 8.4% 左右。

### 2.4.3 CNN+X

对与卷及神经网络与分类器 X 的融合，其算法原理如图 2.30，首先考虑 svm 与 VGGNet 所更改的网络的融合，其结果如表 ??

model	softmax	cnsvm,linear	cnsvm,poly	cnsvm,rbf	cnsvm,sigmoid
CNN-A	0.652202	0.649649	0.654116	0.167837	0.110402
CNN-B	0.664327	0.642629	0.701340	0.219528	0.084876
CNN-C	0.673899	0.639438	0.693044	0.248883	0.156988
CNN-D	0.659860	0.624123	0.682195	0.375877	0.127632

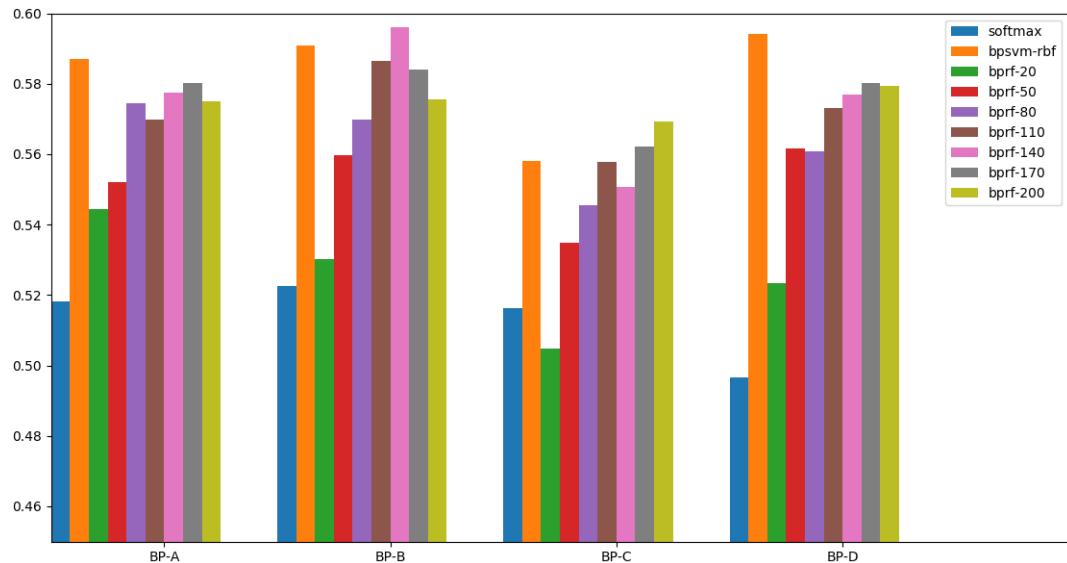
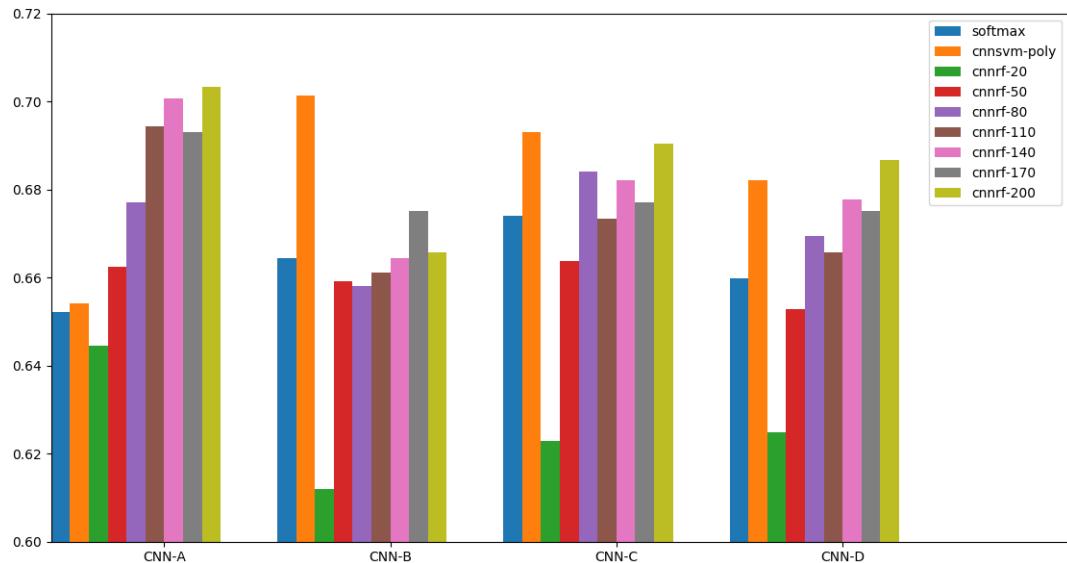


图 2.33 原始的 BP-A,BP-B,BP-C,BP-D,bpsvm-rbf, 与用包含不同树桩个数的随机森林替 softmax 层所得的准确率图

model	softmax	cnsvm,poly	nrf,20	nrf,50	nrf,80
CNN-A	0.652202	0.654116	0.644544	0.662412	0.671985
CNN-B	0.664327	0.701340	0.611997	0.659221	0.647096
CNN-C	0.673899	0.693044	0.622846	0.663689	0.672623
CNN-D	0.659860	0.682195	0.624761	0.652840	0.668156
model	nrf,110	nrf,140	nrf,170	nrf,200	nrf,230
CNN-A	0.677090	0.694320	0.700702	0.693044	0.703255
CNN-B	0.657945	0.661136	0.664327	0.675176	0.665603
CNN-C	0.684110	0.673261	0.682195	0.677090	0.690491
CNN-D	0.669432	0.665603	0.677728	0.675176	0.686662



BP 神经网络 +CART。model A 指  $64 \times 64$ , 隐含层神经元个数为 1000; model B 指  $96 \times 96$ , 隐含层神经元个数为 1000; model C 指  $96 \times 96$ , 隐含层神经元个数为 500; model D 指  $96 \times 96$ , 隐含层神经元个数为 500, 正则化系数为 0.0001。

## 2.5 参考文献

- [1] Kaiming He, Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification, <https://arxiv.org/abs/1502.01852>



## 第3章 结论

如来说道：“圣僧，汝前世原是我之二徒，名唤金蝉子。因为汝不听说法，轻慢我之大教，故贬汝之真灵，转生东土。今喜皈依，秉我迦持，又乘吾教，取去真经，甚有功果，加升大职正果，汝为旃檀功德佛。孙悟空，汝因大闹天宫，吾以甚深法力，压在五行山下，幸天灾满足，归于释教；且喜汝隐恶扬善，在途中炼魔降怪有功，全终全始，加升大职正果，汝为斗战胜佛。猪悟能，汝本天河水神，天蓬元帅。为汝蟠桃会上酗酒戏了仙娥，贬汝下界投胎，身如畜类。幸汝记爱人身，在福陵山云栈洞造孽，喜归大教，入吾沙门，保圣僧在路，却又有顽心，色情未泯。因汝挑担有功，加升汝职正果，做净坛使者。”八戒口中嚷道：“他们都成佛，如何把我做个净坛使者？”如来说道：“因汝口壮身慵，食肠宽大。盖天下四大部洲，瞻仰吾教者甚多，凡诸佛事，教汝净坛，乃是个有受用的品级。如何不好——沙悟净，汝本是卷帘大将，先因蟠桃会上打碎玻璃盏，贬汝下界，汝落于流沙河，伤生吃人造孽，幸皈吾教，诚敬迦持，保护圣僧，登山牵马有功，加升大职正果，为金身罗汉。”又叫那白马：“汝本是西洋大海广晋龙王之子。因汝违逆父命，犯了不孝之罪，幸得皈身皈法，皈我沙门，每日家亏你驮负圣僧来西，又亏你驮负圣经去东，亦有功者，加升汝职正果，为八部天龙。”

因此：

- 唐僧封为旃檀功德佛；
- 孙悟空封为斗战胜佛；
- 猪八戒封为净坛使者；
- 沙和尚封为金身罗汉；
- 白龙马封为八部天龙。
- 华师是个好学校。



## 附录 A 外文资料原文

### A.1 first principles

#### A.1.1 Typography exists to honor content.

Like oratory, music, dance, calligraphy – like anything that lends its grace to language – typography is an art that can be deliberately misused. It is a craft by which the meanings of a text (or its absence of meaning) can be clarified, honored and shared, or knowingly disguised.

In a world rife with unsolicited messages, typography must often draw attention to itself before it will be read. Yet in order to be read, it must relinquish the attention it has drawn. Typography with anything to say therefore aspires to a kind of statuesque transparency. Its other traditional role is durability: not immunity to change, but a clear superiority to fashion. Typography at its best is a visual form of language linking timelessness and time.

One of the principles of durable typography is always legibility; another is something more than legibility: some earned or unearned interest that gives its living energy to the page. It takes various forms and goes by various names, including serenity, liveliness, grace and joy.

These principles apply, in different ways, to the typography of business cards, instruction sheets and postage stamps, as well as to editions of religious scriptures, literary classics and other books that aspire to join their ranks. Within limits, the same principles apply even to stock market reports, airline schedules, milk cartons, classified ads. But laughter, grace and joy, like legibility itself, all feed on meaning, which the writer, the words and the subject, not the typographer, must generally provide.

In 1770, a bill was introduced in the English Parliament with the following provisions:

... all women of whatever age, rank, profession, or degree, whether virgins, maids, or widows, that shall ... impose upon, seduce, and betray into matrimony, any of His Majesty's subjects, by the scents, paints, cosmetic washes, artificial teeth, false hair, Spanish wool, iron stays, hoops, high heeled shoes [or] bolstered hips shall incur the penalty of the law in force against witchcraft ... and ... the marriage, upon conviction, shall stand null and void.

The function of typography, as I understand it, is neither to further the power of witches nor to bolster the defenses of those, like this unfortunate parliamentarian, who live in terror of being tempted and deceived. The satisfactions of the craft come from elucidating, and perhaps even ennobling, the text, not from deluding the unwary reader by applying scents, paints and iron stays to empty prose. But humble texts, such as classified ads or the telephone directory, may profit as much as anything else from a good typographical bath and a change of clothes. And many a book, like many a warrior or dancer or priest of either sex, may look well with some paint on its face, or indeed with a bone in its nose.

### A.1.2 Letters have a life and dignity of their own.

Letterforms that honor and elucidate what humans see and say deserve to be honored in their turn. Well-chosen words deserve well-chosen letters; these in their turn deserve to be set with affection, intelligence, knowledge and skill. Typography is a link, and it ought, as a matter of honor, courtesy and pure delight, to be as strong as the others in the chain.

Writing begins with the making of footprints, the leaving of sighs. Like speaking, it is a perfectly natural act which humans have carried to complex extremes. The typographer's task has always been to add a somewhat unnatural edge, a protective shell of artificial order, to the power of the writing hand. The tools have altered over the centuries, and the exact degree of unnaturalness desired has varied from place to place and time to time, but the character of the essential transformation between manuscript and type has scarcely changed.

The original purpose of type was simply copying. The job of the typographer was to imitate the scribal hand in a form that permitted exact and fast replication. Dozens, then hundreds, then thousands of copies were printed in less time than a scribe would need to finish one. This excuse for setting texts in type has disappeared. In the age of photolithography, digital scanning and offset printing, it is as easy to print directly from handwritten copy as from text that is typographically composed. Yet the typographer's task has little changed. It is still to give the illusion of superhuman speed and stamina – and of superhuman patience and precision – to the writing hand.

Typography is just that: idealized writing. Writers themselves now rarely have the calligraphic skill of earlier scribes, but they evoke countless versions of ideal script by their varying voices and literary styles. To these blind and often invisible visions, the typographer must respond in visible terms.



## 附录 B 其它附录

其它附录的内容可以放到这里，当然如果你愿意，可以把这部分也放到独立的文件中，然后将其 \input 到主文件中。



## 致 谢

首先要感谢党，感谢国家！

这份模板的制作首先得到了我的导师计算机学院李兴民教授，以及计算机学院陈寅副教授的热心支持，衷心感谢他们的教诲和指导意见！

除此之外，还要感谢计算机学院的卓雄辉书记、雷蕾副书记、汤庸院长、单志龙副院长、王立斌副教授等，感谢他们对我的鼓励和帮助。

在做这个模板的时候也获得了其他高校的 `TeXer` 们的帮助，尤其是国防科大的 `NudtPaper` 和清华大学的 `Thu-Thesis`，如果没有这些前辈们的工作，这份模板也不可能这么快出来和大家见面。另外，感谢戴高远，潘嘉昕，高有等同学为这个模板提供了很多宝贵的素材和建议，感谢周晓倩同学和莫城为同学参与模板的测试工作。

感谢以上所有人的努力付出，希望 `SCNUTHesis` 能够在未来的日子里成为 `SCNUer` 们的毕业论文好帮手，帮助大家完成格式规范、排版精美的论文！



## 作者攻读学位期间发表的学术论文目录

### 发表的学术论文

- [1] Yang Y, Ren T L, Zhang L T, et al. Miniature microphone with silicon-based ferroelectric thin films. *Integrated Ferroelectrics*, 2003, 52:229-235. (SCI 收录, 检索号:758FZ.)
- [2] 杨轶, 张宁欣, 任天令, 等. 硅基铁电微声学器件中薄膜残余应力的研究. *中国机械工程*, 2005, 16(14):1289-1291. (EI 收录, 检索号:0534931 2907.)
- [3] 杨轶, 张宁欣, 任天令, 等. 集成铁电器件中的关键工艺研究. *仪器仪表学报*, 2003, 24(S4):192-193. (EI 源刊.)
- [4] Yang Y, Ren T L, Zhu Y P, et al. PMUTs for handwriting recognition. In press. (已被 *Integrated Ferroelectrics* 录用. SCI 源刊.)
- [5] Wu X M, Yang Y, Cai J, et al. Measurements of ferroelectric MEMS microphones. *Integrated Ferroelectrics*, 2005, 69:417-429. (SCI 收录, 检索号:896KM.)
- [6] 贾泽, 杨轶, 陈兢, 等. 用于压电和电容微麦克风的体硅腐蚀相关研究. *压电与声光*, 2006, 28(1):117-119. (EI 收录, 检索号:06129773469.)
- [7] 伍晓明, 杨轶, 张宁欣, 等. 基于 MEMS 技术的集成铁电硅微麦克风. *中国集成电路*, 2003, 53:59-61.

### 研究成果

- [1] 任天令, 杨轶, 朱一平, 等. 硅基铁电微声学传感器畴极化区域控制和电极连接的方法: 中国, CN1602118A. (中国专利公开号.)
- [2] Ren T L, Yang Y, Zhu Y P, et al. Piezoelectric micro acoustic sensor based on ferroelectric materials: USA, No.11/215, 102. (美国发明专利申请号.)